

Book-Crossing 图书推荐数据 ETL 与可视化分析

一、项目背景

- **数据来源：**Kaggle Book-Crossing 社区真实数据集（Books / Users / Ratings）
- **数据规模：**三表合计约 **170 万**条原始记录
- **业务目标：**清洗噪声数据并入库，搭建图书推荐分析看板，支撑用户画像与评分分析
- **技术栈：**Kettle 9.4（PDI）+ MySQL 9.4 + FineBI 6.0 + DataGrip

二、ETL 清洗步骤

表名	原始行数	清洗后
Ratings	1,149,780	433,671
Users	278,858	278,858
Books	271,360	266,727

1. Ratings

核心清洗动作

- ① 过滤 Book-Rating > 0（剔除 62% 隐式0分评分）
- ② 按 User-ID + ISBN 组合去重

2. Users

核心清洗动作

- ① Age 空值替换为 -1（共填充 110,762 条）
- ② 去重

关键问题与解决

Phone 被误判为 DECIMAL(255) → 改为 String(50);

Location 字段长度不足 → VARCHAR(255);

Kettle 字段选择无默认值功能 → 改用 **JavaScript 组件**处理空值

3. Books

核心清洗动作

- ① 年份字段提取纯数字（解决出版社名称混入）
- ② HTML 实体解码
- ③ 去空格/回车/制表符
- ④ 过滤作者/书名/ISBN 为空
- ⑤ 校验 ISBN 长度（仅保留 10/13 位）
- ⑥ 按 ISBN 去重

关键问题与解决

Author/Book-Title 字段长度不足 → VARCHAR(255)/TEXT;

Year-Of-Publication 混入 "DK Publishing Inc" →

CSV 输入先按 String 读入，用**计算器组件**提取纯数字生成 Year_Clean;

过滤条件对 NULL 判断异常 → 先提取数字再过滤

三、SQL 补充清洗与数据增强

1. Location 字段拆分

Users 表中的 Location 字段包含"国家, 省/州, 城市"混合信息，用 SQL 拆分为三列

2. 创建地理层级视图（支持钻取）

3. 创建视图: 订单最多的 Top 10 国家及各省/城市分布

四、验证 SQL

-- 直接验证三表最终数据量

```
SELECT 'books_1' AS table_name, COUNT(*) AS row_count FROM books_1
UNION ALL
SELECT 'users' AS table_name, COUNT(*) AS row_count FROM users
UNION ALL
SELECT 'ratings' AS table_name, COUNT(*) AS row_count FROM ratings;
```

	table_name	row_count
1	books_1	266727
2	users	278858
3	ratings	433671

-- 2. 验证主键唯一性 (无重复)

```
SELECT COUNT(*), COUNT(DISTINCT ISBN) FROM books_1; -- 271,360 / 266,727 (清洗后有重复 ISBN)
```

	COUNT(*)	COUNT(DISTINCT ISBN)
1	266727	266419

```
SELECT COUNT(*), COUNT(DISTINCT 'User-ID') FROM users;
```

-- 278,858 / 278,858 (无重复)

	COUNT(*)	COUNT(DISTINCT 'User-ID')
1	278858	278858

```
SELECT COUNT(*), COUNT(DISTINCT 'User-ID', ISBN) FROM ratings;
```

-- 1,149,780 / 433,671 (组合去重后)

	COUNT(*)	COUNT(DISTINCT 'User-ID', ISBN)
1	433671	433671

```
SELECT COUNT(*) FROM users WHERE Age IS NULL;
```

	COUNT(*)
1	0

```
SELECT COUNT(*) FROM users WHERE Age = -1;
```

	COUNT(*)
1	110762

```
SELECT COUNT(*) FROM books_1 WHERE 'Book-Author' IS NULL OR 'Book-Author' = '';
```

	COUNT(*)
1	0

```
SELECT COUNT(*) FROM users WHERE Location IS NOT NULL AND Country IS NULL;
```

	COUNT(*)
1	0

五、FineBI 看板组件清单

图书推荐数据集可视化分析仪表板

Book Recommendation Dataset

总用户数

总用户数
167,723

总图书数

总图书数
266,419

总评分次数

总评分次数
433,671

平均评分

平均评分
7.6

年份

无限制


年龄分组

无限制

国家

无限制


热门图书评分榜TOP10




评分人数Top1000图书




热门图书评分榜TOP10



评分人数Top1000图书




用户年龄评分分析



用户地域分布

国家	总用户数
United States	76,393
Spain	12,556
United Kingdom	12,492
Canada	11,371
Germany	10,580
Australia	8,868

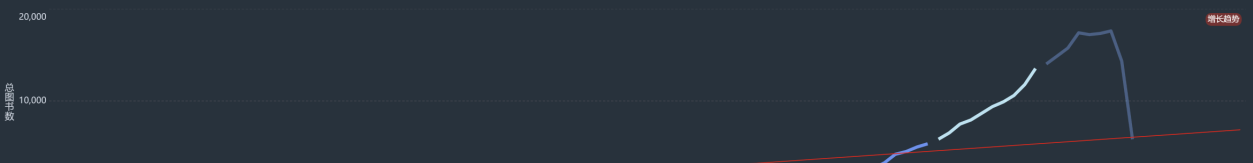
用户年龄评分分析



用户地域分布

国家	总用户数
United States	76,393
Spain	12,556
United Kingdom	12,492
Canada	11,371
Germany	10,580
Australia	8,868
Italy	5,368
France	2,999
Portugal	2,665
China	1,056

年度出版趋势分析




年度出版趋势分析




国家	总用户数
United States	4,067
Spain	1,098
United Kingdom	663
Canada	561
Germany	558
Italy	451
Australia	444
Portugal	233
France	207
China	51


年度出版趋势分析



评分人数Top1000图书



用户年龄评分分析



热门图书评分榜TOP10

