

图书销售数据 ETL 与可视化分析项目

一、项目背景

- 数据来源：Kaggle Books Data Set（三张 CSV 表：books、customers、orders）
- 数据规模：共 1,500 条记录（每张 500 条）
- 业务目标：清洗原始数据并入库，搭建销售分析看板，实现销售概况、畅销排行、地理分布、时间趋势四个维度的可视化监控
- 技术栈：Kettle 9.4（PDI） + MySQL 9.4 + FineBI 6.0 + DataGrip

二、ETL 清洗步骤（三张表）

表名	清洗步骤	遇到问题	解决方案
books	CSV输入 → 字段选择/改名 → 去重（按Book_ID） → 表输出到MySQL	无	—
customers	CSV输入 → 字段选择/改名 → 排序 → 去重（按Customer_ID） → 表输出	Phone字段被误判为DECIMAL(255)，精度超限（最大65）	在"字段选择"中修改Phone为String(50)
orders	CSV输入 → 字段选择/改名 → 排序 → 去重（按Order_ID） → 表输出	无	—

使用 Kettle 完成三张 CSV 表的抽取-清洗-装载，关键处理包括字段类型修正（Phone 精度越界）、去除重复记录、统一日期格式与字段映射，最终落地 MySQL。

三、验证 SQL（DataGrip 执行）

1. 验证总记录数

```
SELECT COUNT(*) FROM books;
SELECT COUNT(*) FROM customers;
SELECT COUNT(*) FROM orders;
```

```
SELECT COUNT(*) FROM books;
```

	1
	500

```
SELECT COUNT(*) FROM customers;
```

	1
	500

```
✓ SELECT COUNT(*) FROM orders;
```

	1
	500

2. 验证去重效果

```
SELECT COUNT(DISTINCT Book_ID) FROM books;
SELECT COUNT(DISTINCT Customer_ID) FROM customers;
SELECT COUNT(DISTINCT Order_ID) FROM orders;
```

```
SELECT COUNT(DISTINCT Book_ID) FROM books;
```

	1
	500

```
SELECT COUNT(DISTINCT Customer_ID) FROM customers;
```

	1
	500

```
SELECT COUNT(DISTINCT Order_ID) FROM orders;
```

	1
	500

3. 验证关联完整性

```
SELECT COUNT(*)
FROM orders o
LEFT JOIN books b ON o.Book_ID = b.Book_ID
LEFT JOIN customers c ON o.Customer_ID = c.Customer_ID
WHERE b.Book_ID IS NULL OR c.Customer_ID IS NULL;
```

✓

```
SELECT COUNT(*)
FROM orders o
      LEFT JOIN books b ON o.Book_ID = b.Book_ID
      LEFT JOIN customers c ON o.Customer_ID = c.Customer_ID
WHERE b.Book_ID IS NULL OR c.Customer_ID IS NULL;
```

1

0

1

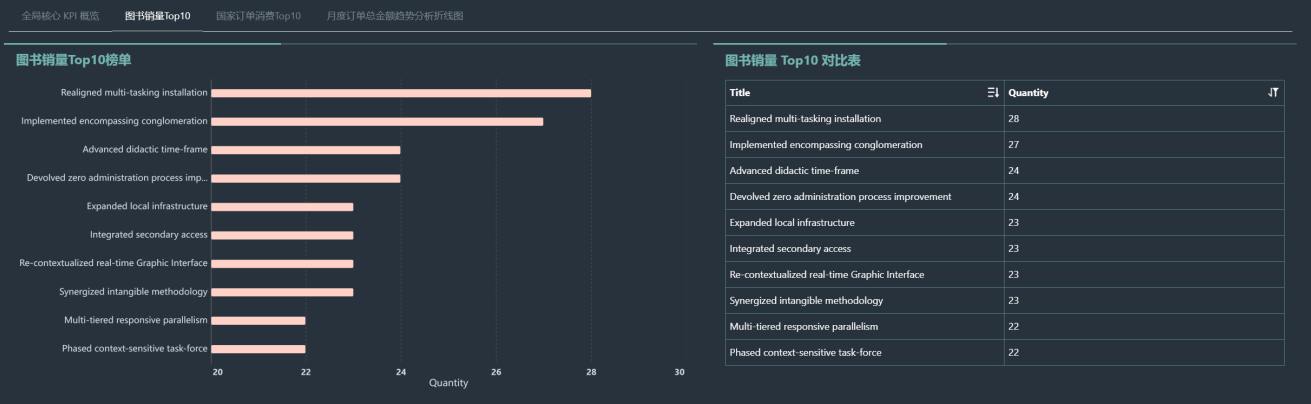
0

四、FineBI 看板组件


序号	图表类型	分析维度	保留理由
①	KPI 卡片 (3张)	总销售额、客户总数、图书种类数	核心概览指标，必须保留
②	柱形图	图书销量 Top10	畅销排行，业务决策最直接
③	环形图	Top10 国家订单消费金额占比	地理分布，直观展示区域贡献
④	对比表	图书销量 Top10（含具体数值）	补充柱形图的精确数据
⑤	折线+面积图	月度订单总金额趋势 + 环比增长率	时间趋势，监控销售波动



Books Data Set 图书销售数据可视化分析



Books Data Set 图书销售数据可视化分析



Books Data Set 图书销售数据可视化分析

